

单位代码 10006
学 号 xxxxxx
分 类 号 xxxxxxx

毕业设计（开题报告）

题 目 _____

学院名称 生物与医学工程学院

专业名称 生物医学工程

学生姓名 Xxxx

指导教师 Xxxx

2026 年 3 月

目 录

1 论文选题依据	1
1.1 研究意义	1
1.2 研究现状分析	2
1.2.1 最小二乘与线性统计推断的演进历史	2
1.2.2 深度学习中的不确定性量化与异方差陷阱	3
1.2.3 保形预测 (Conformal Prediction) 与无分布区间估计	5
1.2.4 医学大模型评估体系与可靠性挑战	5
2 研究方案	6
2.1 研究目标	6
2.2 研究内容	6
2.2.1 异方差加权最小二乘输出头的架构设计	6
2.2.2 β -NLL 修正与稳健似然训练	7
2.2.3 贝叶斯最后一层近似推断与分布漂移预警	7
2.2.4 分布无关的保形预测校准与高能效区间构建	7
2.3 研究方案	7
2.3.1 实验数据资源与特征工程处理	8
2.3.2 模型架构搭建与特征提取	8
2.3.3 数值稳定求解方案	9
2.3.4 CH-WLS 闭环与保形预测实施步骤	9
2.3.5 全面深入的模型评价指标与统计检验体系	9
2.4 研究创新点	10
2.5 预期研究结果	11
3 研究可行性分析	11
3.1 理论基础依据深厚	12
3.2 公开高质量医学基准数据集的可及性	12
3.3 软件生态与算法的工程技术储备完善	12
3.4 计算资源充足与任务时间窗合理	12
4 研究工作计划	12
5 参考文献	14

1 论文选题依据

1.1 研究意义

由于人工智能技术近年来迅猛发展，故大型语言模型（Large Language Models, LLMs）及深度学习技术在医疗健康领域的应用已经从理论探索顺利地进入临床实际部署的阶段。以 Med-PaLM 2 和 Med-Gemini 为代表的医疗大模型在医学问答、电子病历分析、医学影像辅助诊断诸种复杂推理任务中都取得了接近甚至超越人类专家水平的性能表现 [1]。更重要的是，二者都经过对海量医学文本、临床指南、多模态医学数据的充分预训练，并辅以恰当的指令微调，因而具有极其可靠的表征提取能力和上下文学习能力 [2]。但毋庸讳言，医学属于典型的高风险（High-stakes）领域，因此对预测模型的安全性、可靠性、可解释性都有极其严格、不可放松的要求。故而在临床决策支持系统中，单纯依靠模型给出的单一、确定的点预测结果是不够的，若使用不当极有可能造成严重的医疗事故 [3]。

深度神经网络在医学应用中所遇到的最核心、最致命的问题可以十分自然、妥帖地归纳为“过度自信”（Overconfidence）及概率未校准（Poor Calibration）问题：目前经过充分微调的大型语言模型对自身生成的错误预测或幻觉都赋予极高的置信度概率 [5]。而临床医生若依靠此类未校准的系统来做疾病诊断、ICU 住院时长预估或死亡风险分析，那么模型在面对分布外数据或模棱两可的临床特征时所作的盲目自信的判断，就会直接剥夺医生及时干预、纠正错误的机会 [3]。因此，不确定性量化（Uncertainty Quantification, UQ）及可信区间预测应当成为医学人工智能系统走向实际落地时绝对不可绕开的先决条件 [8]。

由于本课题的提出本身就是为了解决医学大模型在结构化预测任务中不确定性量化的理论及工程两重瓶颈，故而本文自然、妥帖地摒弃了传统深度学习中被当作“黑箱”处理的全连接层分类器或回归器，转而把经典且有明确统计学保证的最小二乘估计（Least Squares Estimation, LSE）理论直接、合理地引入医学大模型的输出层。因此其重要意义可以很自然地归纳为三个方面。

第一，本文对经典统计推断与现代深度表征学习的融合做了十分自然、严谨的理论阐述：最小二乘法是统计学的基础方法，在处理异方差、多重共线性问题时有 Gauss-Markov 定理及广义最小二乘法等成熟、完备的理论工具 [10]。因此把最小二乘推断直接、合理地重构为大模型的结构化输出头，既让模型在潜在高维特征空间中显式地对不同患者噪声水平（轻症、重症患者的生理指标波动）做精确加权建模，又自然而然地赋予了模型预测结果明确、扎实的统计学可解释性。

第二，本文对安全性及伦理性两方面都做了十分严谨、有层次的安排，即建立了无分布假设的严格安全底线：传统贝叶斯神经网络及深度集成方法在估计模型不确定性时都隐含地作了对数据生成分布或先验分布的强假设，而这类假设在跨院区、跨时段的真实医疗场景中极易因分布偏移而被推翻 [12]。故而本文自然、妥帖地引入了保形预测技术，在仅假定数据满足微弱可交换性前提的情况下，直接给出对任意给定显著性水平都

有有限样本覆盖率保证的预测区间 [14]。更难得的是，由此得到的数学机制能严格保证真实疾病风险落入预测区间，因此也极大增强了医疗人工智能系统的透明度及伦理合规性 [16]。

第三，本文从临床实用性的角度非常自然、妥帖地解决了预测区间“既要安全，又要精准”的效率难题：保形预测固然能保证覆盖率，但是若所得预测区间过于宽泛，就没有临床参考价值。因此作者设计了异方差加权最小二乘网络层，再结合共形分位数回归技术，让预测区间能根据个体患者的特征自动、合理地进行缩放 [17]。具体而言，对特征明确、不确定性极小的患者给出较窄的精准区间，对临床信息缺失或处于分布边缘的患者给出较宽的区间并主动触发临床报警系统予以风险提示。故而所提出的方法很好地满足了临床决策中效率与安全性的折中需求，也由此顺理成章地给出了构建真正可用的人机协同医疗诊断系统的明确理论框架及技术路线。

1.2 研究现状分析

由于要系统、有层次地建立本课题的研究框架，厘清医学大模型不确定性量化的发展脉络，故本节拟先回顾最小二乘估计的历史演进，再介绍深度学习中不确定性理论的基本观点，继而讨论保形预测技术的最新进展，然后自然、流畅地引出医疗大模型在评估、部署阶段所遇诸种问题及现有方法的不足，最后提出本课题的理论思路。

1.2.1 最小二乘与线性统计推断的演进历史

最小二乘法 (Method of Least Squares) 是现代统计推断和机器学习优化的基石，其发展历史可以追溯到 19 世纪初。法国数学家 Adrien-Marie Legendre 在其 1805 年出版的关于彗星轨道确定的著作中，首次公开发表了最小二乘法的代数拟合过程，提出通过最小化观测值与模型预测值之差的平方和来确定未知参数 [18]。随后，Carl Friedrich Gauss 在 1809 年发表了将其与概率分布论相结合的工作，并声称其自 1795 年起便使用了该方法 [20]。Gauss 与 Andrey Markov 的工作最终奠定了著名的 Gauss-Markov 定理：在误差项期望为零、同方差且互不相关的假设下，普通最小二乘估计量 (OLS) 在所有线性无偏估计量中具有最小的抽样方差，即它是最佳线性无偏估计量 (BLUE) [11]。

表 1: 最小二乘法演进与核心特征

方法名称	提出者与时间	核心解决问题	理论机制与特点
普通最小二乘 (OLS)	Legendre (1805)	基础参数估计与拟合	最小化残差平方和，在同方差假设下为 BLUE [11]。
广义最小二乘 (GLS)	Aitken (1935)	异方差与误差相关性	引入非标量误差协方差矩阵，对数据进行白化变换后估计 [10]。
岭回归 (Ridge)	Hoerl & Kennard (1970)	多重共线性与病态矩阵	在协方差矩阵对角线引入非负惩罚项，稳定数值求解 [23]。
Tikhonov 正则化	Tikhonov (1963)	不适定反问题	引入解范数惩罚项，等价于贝叶斯最大后验估计 (MAP) [24]。
M-估计 (M-estimation)	Huber (1964)	离群点与重尾噪声敏感性	用稳健损失函数（例如 Huber 损失）替换平方损失，降低极端值的影响 [25]。

由于医疗数据实际应用中 Gauss-Markov 定理所赖以成立的同方差假设几乎必然被打破，不同医疗机构设备的精度差异、不同严重程度患者生理体征的波动率差异都会导致误差方差随输入特征的变化而变化，因此 A. C. Aitken 在 1935 年自然、妥帖地提出了广义最小二乘法 (GLS)，并严格证明了：当误差协方差矩阵为已知正定矩阵时，GLS 能重新获得 BLUE 性质 [10]。更重要的是，医学数据集本身一般高维且特征高度共线，故正规方程中所涉系数矩阵的条件数极大，数值求解时极易出现剧烈震荡。为解决此类病态问题，Arthur E. Hoerl 和 Robert W. Kennard 在 1970 年提出了岭回归 (Ridge Regression)，给出了极其清楚而优雅的结果：适当引入微小偏差能极大降低估计的方差 [23]。巧合的是，A. N. Tikhonov 在 1963 年对不适定问题所提出的正则化方法与岭回归在数学形式上殊途同归 [24]。

由于传统平方损失函数对医疗记录中常见离群点十分敏感，即容易被极端残差主导而使模型失效，故 Peter J. Huber 在 1964 年提出了稳健估计中著名的 M 估计理论，巧妙地设计了损失函数及其影响函数，在保证高斯分布下高效率的同时大大提高了对污染数据的抗干扰能力 [25]。更重要的是，现代统计学中已有成熟、自然的做法：用 Student- t 分布等重尾似然函数构造稳健模型，其相应的最大似然估计可直接、合理地用迭代重加权最小二乘 (IRLS) 算法转化为自适应的加权计算过程。因此，该经典理论为本课题把最小二乘机制深度嵌入大模型输出层提供了极其扎实、完备的数学基础。

1.2.2 深度学习中的不确定性量化与异方差陷阱

深度神经网络在医学分类、回归任务中有极好的拟合能力，但是毋庸讳言，Chuan Guo 等人于 2017 年已经十分清楚、严谨地说明了：现代神经网络虽然准确率越来越高，

但是所得到的输出概率的校准程度远不如十年前的浅层网络，因而存在严重的过度自信问题 [5]。在医疗决策中，此类高置信度的错误预测无疑是危险的。

由于深度学习社区对不确定性量化已有十分扎实、有层次的研究，因此 Alex Kendall 和 Yarin Gal 在 2017 年从贝叶斯深度学习的角度对神经网络中所遇不确定性做了极其自然、清楚的两类划分：

- **数据不确定性 (Aleatoric Uncertainty)** 是由数据本身的固有噪声或标签模糊性引起的，故不能单纯靠增加训练样本予以消除，在回归问题中这类不确定性最自然、最典型地表现为异方差性 (Heteroscedasticity)，因此宜让网络直接预测与输入有关的方差。
- **模型不确定性 (Epistemic Uncertainty)** 是模型参数认识不足所致，故一般出现在训练数据稀疏的分布外区域，而从理论上又可以十分自然、合理地认为，增大训练数据量即可消除此种不确定性。

表 2: 深度学习中两类不确定性的对比

不确定性类型	产生根源	特性	应对方法
Aleatoric (数据不确定性)	传感器噪声、记录偏差、固有生物学变异	不可随数据量增加而消除	异方差高斯/Student- t 负对数似然输出 [27]。
Epistemic (模型不确定性)	训练数据不足、模型容量限制、认知盲区	可随数据量增加而逐渐消除	贝叶斯神经网络、蒙特卡洛 Dropout 和深度集成等方法。

Balaji Lakshminarayanan 等人所提出的深度集成方法将若干随机初始化的神经网络自然、合理地结合起来，因此被公认为非贝叶斯阵营中估计 Epistemic 不确定性、处理分布偏移时的基准 [12]。但毋庸讳言，在基础大模型时代，对动辄几十亿参数的大模型做全参数集成训练或者贝叶斯推断显然是计算上不可接受的。故而学界很快转向研究“贝叶斯最后一层 (Bayesian Last Layer, BLL)”技术：冻结深层特征提取器，只把网络输出层的权重视为随机变量并做贝叶斯后验推断，由此在几乎不增加计算负担的前提下直接、可靠地估计模型不确定性 [28]。

此外，由于对 Aleatoric 不确定性做异方差建模时直接最小化高斯负对数似然会有隐蔽的优化陷阱，因此 Maximilian Seitzer 等人于 2022 年十分自然、严谨地指出了：用梯度下降法优化异方差高斯 NLL 时，均值、方差梯度强耦合，故模型很容易陷入所谓“劣解稳定”状态，进而使方差估计严重偏离真实噪声分布 [30]。由此也自然地引出他们所提出的 β -NLL 损失函数，该损失函数用指数衰减权重切断恶意梯度传播，因而极大提高了异方差估计的鲁棒性。因此本课题的输出头设计将把此优化策略完整、合理地加以整合，让医学大模型在复杂噪声环境中稳定收敛。

1.2.3 保形预测 (Conformal Prediction) 与无分布区间估计

由于深度集成及近似贝叶斯推断中所作的不确定性估计都以模型架构选择、分布先验设定为基本前提，而目前尚不能严格证明医疗辅助诊断中常用的启发式不确定性度量能转化为真实的错误率概率，故其临床采信度自然大打折扣。因此保形预测理论就是为解决这个问题而设计的。

Glenn Shafer 和 Vladimir Vovk 于 2008 年对保形预测理论做了十分清楚、严谨的系统阐述 [14]，即用新样本与已有经验之间的非一致性分数来构造含有真实标签的预测集，而其最重要的理论贡献是：若假设训练集、测试集数据满足可交换性，那么保形预测可以自然、可靠地给出有严格有限样本边缘覆盖率保证的区间估计，且该结论与所用底层机器学习算法的具体形式无关 [15]。

然而，医疗数据回归任务中所用的基础分割保形预测方法有很好的安全性，但是也毋庸讳言其输出的预测区间宽度固定，因此在异质性极强的临床群体中必然缺乏效率：对症状轻微、特征明确的患者，区间过于保守，而对危重患者又不能充分反映更大的波动范围。为自然、合理地解决这个问题，Yaniv Romano 等人于 2019 年提出了共形分位数回归 (Conformalized Quantile Regression, CQR) [17]。CQR 非常巧妙地把分位数回归对局部数据变异的高度敏感性与 CP 的覆盖率保证结合起来：先用神经网络估计目标变量的上下分位数，再根据校准集上的分位数残差对区间做自适应扩张或收缩。更重要的是，大量在表观遗传数据及医疗时序分析中的应用已经充分、严谨地验证了，基于异方差机制调整的 CP 区间在保持无偏覆盖率的同时平均区间宽度大大缩小，因而不确定性量化的实际应用价值极大提高 [32]。

1.2.4 医学大模型评估体系与可靠性挑战

由于目前医学领域的 AI 研究基本上由大型语言模型所支配，故而 Med-PaLM 2 在基础大模型升级、医学领域微调、检索链诸种提示策略上都设计得十分巧妙，在 MedQA 数据集上取得了 86.5% 的历史性优异结果 [1]。与此形成极好补充的是，Med-Gemini 利用长上下文推理及多模态微调能力，在 14 项医学基准测试中刷新了 10 项 SOTA 记录 [2]。

然而，精度的胜利遮蔽了模型在不确定性校准上所隐含的重大问题：从目前对医疗大模型的基准测试中已经十分清楚地看到，即使是最先进的模型也很难可靠、明确地判断自己知识的边界，而近期大量实证研究又一致表明医学大模型在复杂临床推理任务中容易产生高度欺骗性的事实幻觉 [6]。因此，研究者们提出了多种代理指标来度量 LLM 的不确定性，包括词元级概率 (Token-Level Probabilities)、多重生成样本的一致性 (Sample Consistency) 以及信心引出 (Confidence Elicitation) 等 [33]。在评判不同不确定性度量方法的优劣时，学术界已经有了成熟、被广泛接受的标准：期望校准误差和 Brier 分数 [34]。更重要的是，若要严谨地比较不同模型策略所得 AUC 等指标的差异，DeLong 检验和 Bootstrap 自举法自然应当被用作必不可少的统计检验工具 [37]。

综上所述，虽然医学大模型有极好的知识记忆能力和特征表征能力，但是毋庸讳言，

其结构末端缺少统计学上严格意义上的推断能力，因此把经典可靠的最小二乘理论与现代保形预测技术自然、妥帖地结合，可以设计出适用于医学大模型的结构化输出头，在不重新预训练庞大基座模型的前提下直接解决医疗 AI 中长期存在的异方差干扰、离群点敏感、模型过度自信、预测区间宽泛无用诸种痛点。故而本课题的研究方案是对相关文献脉络及技术缺口做了十分清楚的梳理，由此推出真正值得临床信赖的人工智能推理闭环。

2 研究方案

2.1 研究目标

本课题的总体目标十分明确：把经典的最小二乘方法从深度学习中单一、被动的损失函数出发，自然、合理地重构为医学大模型结构中高度可解释、有自适应校准能力的独立预测模块，继而在此基础上建立严谨的优化系统，由此直接、有力地解决医疗 AI 在真实高风险部署中所遇到的可靠性问题。因此可自然、妥帖地划分为三个层次的目标：

- 1. 构造结构化最小二乘输出头 (Structured Least Squares Output Head)：**在冻结医学大模型深层编码器或者做了参数高效微调之后，设计带有岭回归正则化、异方差加权最小二乘 (Heteroscedastic WLS) 及稳健 M 估计的网络输出层，由此自然、妥帖地处理医疗数据中所含的异质性噪声，也直接建立与经典线性统计推断相一致的理论桥梁。
- 2. 实现医疗不确定性的深层解耦及严格校准：**从输出头出发先对数据固有噪声及模型认知不确定性予以明确、独立的量化，然后自然、合理地把二者融入保形预测框架，再借助分位数校准方法，在较弱的可交换性假设下求得有有限样本无偏覆盖率保证且质量极好的可信预测区间。
- 3. 解决可微优化层的数值坍塌陷阱：**把矩阵方程求解器作为可微层嵌入到端到端训练中以后，对正规方程条件数爆炸、异方差似然梯度恶意耦合两者都提出系统的干预方法，再自然、妥帖地结合 QR 分解、Cholesky 分解及 β -NLL 修正技术，由此保证结构化输出头在医学高维特征空间中训练时的数值稳定性。

2.2 研究内容

围绕上述确定的研究目标，本课题的研究内容可以被分为四个有机衔接的模块，即架构设计、模型训练、不确定性提取和最终结果校准。

2.2.1 异方差加权最小二乘输出头的架构设计

由于放弃了传统的多层感知机分类器，故可以把网络的最后一层改为以优化问题为内核的可微求解层，由此很自然地引出一种设计：给定大模型所提取的高维表征，让网

络同时学习两个明确、有层次的预测分支，即预测目标期望值的均值分支及预测数据样本异质性方差的分支，进而构造加权最小二乘框架，让高噪声的医疗样本自动获得较低的权重，也即更小的学习影响。

2.2.2 β -NLL 修正与稳健似然训练

由于传统的深度异方差回归以高斯负对数似然为目标函数来做联合训练，故直接最小化该损失函数时容易出现损失函数中对数惩罚项所引起的均值、方差参数梯度相互干扰的问题，因而很自然地收敛于极差的局部最优解 [30]。因此本文十分自然、妥帖地引入了 β -NLL 修正机制，对方差梯度做截断处理，让方差只调节损失函数的尺度，而不参与均值网络梯度流的更新。更重要的是，电子病历数据中大量存在极端的生理异常值，故本文将高斯似然合理地推广到基于 Student- t 分布的重尾似然函数，借助其对大残差样本惩罚增长缓慢的统计特性，在概率分布的根本层面就赋予输出头抗击离群值 (Outliers) 真正的稳健性。

2.2.3 贝叶斯最后一层近似推断与分布漂移预警

在确定性的最小二乘输出头的基础上自然、合理地实现 BLL 的近似，首先假定输出层权重矩阵服从各向同性高斯先验，由此对一批训练特征矩阵直接做闭式计算，求得后验精度矩阵。再针对任意新输入的医学样本，先预测其数据噪声，继而用基于后验协方差矩阵所诱导的二次型项来系统、严谨地估计模型不确定性 [28]。因此也自然地引出如何利用其作为跨中心部署及时间概念漂移的敏感指示器来构造医疗系统的自动报警机制。

2.2.4 分布无关的保形预测校准与高能效区间构建

本文对从网络中抽离的 Aleatoric 和 Epistemic 不确定性做了自然、合理的整合，先用分割保形预测对独立、同分布的临床校准集上的模型输出予以标定，然后把模型自适应的总不确定性尺度用作非一致性分数的归一化因子。更重要的是，文中系统、严谨地引入了共形分位数回归技术，直接学习分位数的上下限并做恰当的 CP 修正，因此突破了传统保形预测中区间恒定、过于宽泛的根本限制，在保证 90% 或 95% 目标覆盖率的前提下，所得到的预测区间平均宽度大大缩小，十分契合重症监护及精准医疗对置信区间的严苛需求 [17]。

2.3 研究方案

本课题的研究方案具体的实施路径与技术细节如下：

2.3.1 实验数据资源与特征工程处理

为了保证研究结论的普适性与有效性，本方案选取了多个国际公认的医学 AI 基准数据集：

表 3: 实验数据集概览

数据集名称	模态类别	主要研究任务	在本课题中的核心作用
MIMIC-IV [40]	结构化 EHR + 文本	ICU 住院时长 (LOS) 回归预测、败血症死亡风险分类	主线任务：模型训练、异方差建模验证与基准性能评估。
MIMIC-IV-Ext-22MCTS [41]	相对时间戳的临床时序数据	时序风险预警与下一事件预测	检验时序相关数据下的分布偏移情况。
eICU [42]	多中心重症 EHR	与 MIMIC 一致的疾病分类与回归任务	构建独立的外部验证集，实施跨院区零样本漂移测试，检验 CP 区间覆盖率。
CheXpert / MIMIC-CXR [43]	医学胸片影像 + 报告标签	放射学异常多标签分类	对”最小二乘输出头”在视觉大模型 (ViT) 特征提取中的迁移能力做系统检验。

严格的数据划分原则：由于保形预测理论要求严格满足可交换性的前提条件，故本文自然要摒弃简单的随机划分，而应系统、妥帖地采用逐患者分割的数据切分策略，即同一患者的诸次就诊记录绝对不要跨训练、校准、测试集分布 [45]。更重要的是，MIMIC-IV 数据集本身有收治年份信息，因此宜按收治年份做时间切分以模拟时序漂移。

2.3.2 模型架构搭建与特征提取

由于所选的基础模型框架有明确、合理的预训练大模型编码器及结构化最小二乘输出头的设计，故可自然、妥帖地处理文本及序列化 EHR 数据，即用 ClinicalBERT 或预训练 LLaMA 系列的基础参数做特征编码，而影像数据用大规模预训练的视觉 Transformer 模型处理。

在训练开始阶段时会把所有的深层编码器参数都设定为被冻结状态，只优化输出头部分来进行闭式求解和求解得到最快速度下的性能指标基线，之后再利用一些最新的参数高效的微调方法，在最后加入或者解冻非常少的一部分参数，用来对模型进行非常微小的领域微调，用以达到在保持很小计算开销的基础上达到更好的效果。

2.3.3 数值稳定求解方案

由于把岭回归、加权最小二乘方法转化为深度网络最后一层参与反向传播时不能直接用正规方程求解，故而其中所用矩阵会使原始条件数被极大幅度放大，因此当所提取的特征高度共线时，微小的浮点截断误差就会引起梯度爆炸或模型崩溃 [46]。

由于就所论问题已有明确的认识，因此本方案自然、妥帖地提出了两大解决方法：

- **分解算法替换：**由于可以很自然地舍去显式求逆，因此在 GPU 上求解线性系统 [48] 时宜采用基于 Householder 反射的 QR 分解或针对对称正定矩阵设计的 Cholesky 分解：前者数值安全性极高，后者速度快、内存开销小，且附加岭参数之后仍能很好地保留正定性。
- **Woodbury 矩阵恒等式加速：**由于临床特征维数远远大于样本数，故对于小样本迁移学习问题很自然地想到用 Woodbury 矩阵求逆引理把高维矩阵求逆问题转化为低维矩阵求逆问题，由此在保证数值精度的前提下极大提高了端到端反向传播的计算效率。

2.3.4 CH-WLS 闭环与保形预测实施步骤

算法的工程执行按照逻辑划分为四个阶段：

- (1) **异方差基模训练：**由于训练集上输入的各特征经网络求得了预测均值、预测对数方差，因此自然地要用带有截断梯度的 β -NLL 来作反向传播的优化。
- (2) **贝叶斯特征提取：**由于训练已经收敛，故可自然、合理地提取训练集中各特征矩阵，再结合标称方差及先验分布系数来构造后验精度矩阵，由此确定模型认知不确定性的评价基准。
- (3) **独立校准集上的分位数标定：**选择适当规模的校准集，对每个校准样本都计算它们包含 Aleatoric、Epistemic 不确定性的总尺度，得到样本的归一化残差分数，并从分数集合中选择相应分位数标量 [17]。
- (4) **线上推断与可信区间生成：**针对每个测试集的新患者，在输出预期值后，系统还会直接输出基于实时预估得到的严格预测区间。如果预估值存在异常偏高的情况，系统可以直接通过拒识方式阻止不可靠的自动预测进入到终端医生处。

2.3.5 全面深入的模型评价指标与统计检验体系

本研究将超越仅仅汇报 RMSE 或准确率的传统评估模式，建立一套综合反映点预测、概率分布匹配度以及区间安全性三个维度的严谨评价框架。

表 4: 多维度综合评价指标体系

评估维度	指标名称	定义与考核目的
点预测精度	RMSE, MAE, AUROC, AUPRC	衡量模型预测均值的绝对误差以及二分类医学事件的排序区分度 [50]。
概率校准质量	Brier Score, NLL, ECE	评估预测概率值与真实结果发生率之间的拟合程度。Brier 分数严格惩罚了未校准的高置信度 [34]; 期望校准误差通过分箱平均量化了过度自信的程度 [35]。
区间有效性	PICP	衡量测试集中真实结果落入预测区间的比例。其数值必须等于或略高于设定的目标置信水平。
区间效率	MPIW	在 PICP 达标的前提下, 评估区间的宽窄。MPIW 越小, 表明异方差建模及共形缩放越有效, 临床指导价值越高。
临床效用评估	Error-Retention 曲线	按照模型不确定性由高到低逐步剔除测试样本, 绘制剩余样本的精度提升曲线。模拟真实临床中疑难病例交由人类专家、模型处理高确定性常规病例的协同收益。

统计学检验流程: 在对比各种输出头设计的性能差异时, 由于评估是在同一测试集上对多个模型进行的, 简单的 t 检验容易导致假阳性结论。本研究将在 AUROC 比较中强制使用 DeLong 检验 [38]; 而对于无法使用 DeLong 检验的 ECE、Brier 分数及 MAE 等指标, 将采用成对的自举法 (构建 95% 置信区间并进行双侧显著性检验), 从而确保得出经得起评议推敲的统计学结论 [37]。

2.4 研究创新点

由于本课题对医疗大模型研究中所遇到的”重表征轻推断、重精度轻校准”的种种瓶颈有十分清楚的认识, 故能自然、合理地提出若干理论融合的架构设计:

- 1. WLS 与 CP 结合的 CH-WLS 推理框架:** 本文第一次系统、严谨地提出了 WLS 与 CP 相结合的 CH-WLS 推理框架, 对传统医学模型预测区间的问题做了极好的补正: 单纯用保形预测得到的区间过于宽泛, 故缺乏临床实操价值, 而单纯用贝叶斯网络或异方差建模又在分布偏移时失去概率覆盖保障。因此作者在大型基础模型尾端用异方差加权最小二乘方法准确地刻画了各患者内禀数据的不确定性, 让预测区间能自然、合理地随患者病情明确程度自适应缩窄, 继而用保形预测作为最后一道防火墙, 在不假设误差服从高斯分布的前提下对分位数做标定校准, 由此确定严格可靠的无偏覆盖率底线。
- 2. 数值计算与梯度流的双重防坍塌机制:** 由于病态特征空间上求解正则化最小二乘系统时极易出现数值爆炸或梯度恶化, 因此本课题对病态特征空间提出了数值计

算、梯度流两者的双重防坍塌机制：首先舍弃容易导致条件数平方放大的直接正规方程求逆法，转而采用底层实现可微分解的 QR 算法与附带岭惩罚的 Cholesky 分解相结合的策略。更难得的是，针对异方差 NLL 中普遍存在的均值方差梯度恶性耦合所造成的劣解陷阱，本文自然、妥帖地引入了基于截断梯度的 β -NLL 优化策略。由此，两种机制从纯数学的计算稳定性及优化平面的收敛性两个方面完整、严谨地扫清了在端到端深度网络中集成显式统计推断层的技术障碍。

3. **基于认知不确定性分解的医疗分布偏移警示系统：**构建基于认知不确定性分解的医疗分布偏移警示系统时，首先要认识到医疗临床部署中环境跨院区变更、诊疗手段随时调整是常见现象，因而模型精度会有断崖式下跌。因此本创新点十分明确且巧妙：不试图让模型解决所有跨域问题，而是主动、系统地提取 BLL 中所含的模型参数的认知不确定性，将其从不可消除的生理噪声中剥离出来。当系统检测到某个外部验证集上 Epistemic 不确定性异常激增时，即联动 CP 分数放大，生成极宽的报警区间，或者直接触发警示阈值，把决策权正式、安全地移交回主治医师。由此自然妥帖地满足医疗 AI 应用中的伦理合规要求，也切实降低大语言模型幻觉对临床诊断的不利影响。

2.5 预期研究结果

通过本课题的系统性研究，预期将在理论成果、工程代码层面实现以下产出：

1. 形成包含 OLS、GLS、Ridge Regression 在神经网络中反向传播的完备推导体系，并基于 PyTorch 和相关可微优化框架实现具有数值稳定性的 CH-WLS 自定义网络层算子。
2. 在 MIMIC-IV 和 eICU 数据集上严格、清楚地证明所提方案能匹敌或超越传统的深度多层感知机预测头 baseline，且在校准层面有明确优势：即与单纯用温度缩放的方法相比，校准误差、Brier 分数都明显降低。更难得的是，在保证严格 90% 或 95% 预测区间覆盖率的严苛条件下，由于引入了异方差自适应缩放机制，本方案所得平均预测区间宽度比朴素分割保形预测方法缩小 15% 至 30%，因此其预测结果的临床采用率自然大大提高。

3 研究可行性分析

经过前期的文献调研与技术论证，本研究在以下四个层面具备高度的可行性与可预期性：

3.1 理论基础依据深厚

课题有十分扎实、清楚的数学基础：普通最小二乘及广义最小二乘（GLS）的最优性论证从 Gauss、Aitken 时代起就经过了长期、充分的检验，因此很自然地可以作为结构化约束来抑制深度网络参数的过拟合 [10]。更难得的是，保形预测能给出有限样本分布无关的覆盖率保证，Vladimir Vovk 等人对此做了极其严谨、优雅的数学证明 [14]。而 Kendall 等人对深度学习不确定性解耦的工作 [27] 又很好地补充了这一框架。故此，本课题所提出的 CH-WLS 体系在统计学理论上有很好的逻辑连贯性。

3.2 公开高质量医学基准数据集的可及性

医学研究长期面临数据获取困难的重大障碍，而本课题非常自然、妥帖地利用了 MIT 实验室及相关机构所维护、国际学术界普遍认可的若干公开数据集：MIMIC-IV 重症监护电子病历库 [40] 及 MIMIC-IV-Ext-22MCTS [41]，全美几十家医院数据汇集而成的多中心重症数据库 eICU [42]，以及专为验证视觉特征设计的 CheXpert 胸片数据集 [43]。更难得的是，各数据集都含有数十万例完整、高质量的结构化及文本形式的生理记录，且均已被大量应用于临床风险分层、ICU 存活率、住院时长预测的公开研究。

3.3 软件生态与算法的工程技术储备完善

由于在代码实现中把凸优化系统嵌入深度网络并计算反向传播梯度有一定的研究基础，故目前已有 OptNet 和 cvxpylayers 两个十分成熟、可靠的开源框架可供参考 [39]。而更重要的是，HuggingFace 的 transformers 及参数高效微调库 peft 都提供了复杂大模型提取所需的完善 API 接口，由此自然地缩短了基建代码的开发周期。

3.4 计算资源充足与任务时间窗合理

本文对大模型特征提取之后的输出头重构做了十分清楚、有层次的创新说明：即绝大多数实验中先用大模型做正向传播提取患者特征表示并保存到本地，而之后所作的成百上千次输出头训练、异方差优化、 β -NLL 消融实验以及多次 Bootstrap 重采样显著性检验都直接在低维表征矩阵上进行。因此该解耦架构对计算硬件的要求大大降低，现有服务器就能自然、高效地承担所有训练开销，更难得的是还能保留大量算力给大参数数量的 OOD 漂移对照实验，计算流程因而能在规定时间节点内稳妥跑通。

4 研究工作计划

表 5: 研究工作进度安排

进度节点	核心任务模块	具体执行内容与预期输出
第 1–2 周	文献深读与开题答辩	1. 深入研读最小二乘、保形预测、 β -NLL 及医学大模型幻觉与校准的前沿经典文献。
第 3–5 周	数据预处理、baseline 搭建与特征池建立	1. 下载、清洗 MIMIC-IV 和 eICU 数据，对时序特征中所含的缺失值予以合理处理。 2. 用开源医学大模型离线提取所有病历数据的深度表征向量。 3. 用 PyTorch 构造传统的 MLP 预测头及 MSE/Ridge-LS 基线，求取基础 RMSE 及初步 AUC 值。
第 6–8 周	开发异方差 WLS 头	1. 写出异方差加权最小二乘结构化输出头的定制算子的程序。 2. 接入 β -NLL 截断损失函数，并做基于 Student- t 似然的稳健机制替换实验。 3. 训练过程中监控正规方程条件数，让梯度平稳收敛，输出数据不确定性的中间预测结果。
第 9–11 周	共形校准、BLL 集成与中期检查	1. 在网络架构末端挂载 BLL 模块，计算训练集的后验精度矩阵，求取模型认知不确定性。 2. 在独立校准集上作分割保形预测及共形分位数回归，从标定分数出发计算经验分位数，求得自适应预测区间。 3. 计算院内测试集上的 PICP、MPIW 指标，检验是否满足覆盖率目标，并作中期检查答辩准备。
第 12–14 周	跨域漂移测试、多维指标评价与统计学检验	1. 将在 MIMIC-IV 上训练、校准好的模型用零样本推断的方法在 eICU 数据集上做跨中心漂移测试，检验 CP 机制的安全底线是否生效。 2. 计算 Brier Score、ECE 等各种校准评价指标，用 DeLong 检验检验模型 AUC 提高的真实性，用 Bootstrap 方法求取其余指标的 95% 置信区间。 3. 生成反映临床干预效用的 Error-Retention 风险覆盖曲线，并加以系统分析。

进度节点	核心任务模块	具体执行内容与预期输出
第 15–16 周	成果可视化、学术论文撰写与最终答辩准备	1. 梳理全部消融实验的客观数据、图表、算法伪代码及对照表，确保逻辑线条清晰严密。 2. 撰写毕业学术论文。

5 参考文献

- [1] SINGHAL S, et al. Towards expert-level medical question answering with large language models[J/OL]. arXiv preprint arXiv:2305.09617, 2023.
- [2] SAAB S, et al. Capabilities of Gemini models in medicine[J/OL]. arXiv preprint arXiv:2404.18416, 2024.
- [3] Uncertainty-aware large language models for explainable disease diagnosis[J/OL]. PMC. <https://pmc.ncbi.nlm.nih.gov/articles/PMC12627459/>.
- [4] Ethical and legal aspects of healthcare AI: innovation and policy for safe and fair use[J/OL]. PMC. <https://pmc.ncbi.nlm.nih.gov/articles/PMC12076083/>.
- [5] GUO C, PLEISS G, SUN Y, et al. On calibration of modern neural networks[C]//Proceedings of the International Conference on Machine Learning (ICML). 2017.
- [6] Medical hallucination in foundation models and its effect on healthcare[J/OL]. medRxiv, 2025. <https://www.medrxiv.org/content/10.1101/2025.02.28.25323115v2.full.pdf>.
- [7] Development and validation of an interpretable conformal predictor to predict sepsis mortality risk[J/OL]. JMIR, 2024. <https://www.jmir.org/2024/1/e50369/>.
- [8] Benchmarking uncertainty quantification methods for large language models via LM-Polygraph[J]. Transactions of the Association for Computational Linguistics (TACL).
- [9] Privacy-preserving federated learning and uncertainty quantification in medical imaging[J]. Radiology: Artificial Intelligence, 2024.
- [10] AITKEN A C. On least squares and linear combination of observations[J]. Proceedings of the Royal Society of Edinburgh, 1935, 55: 42–48.
- [11] Wikipedia. Gauss–Markov theorem[EB/OL]. https://en.wikipedia.org/wiki/Gauss-Markov_theorem.

- [12] LAKSHMINARAYANAN B, PRITZEL A, BLUNDELL C. Simple and scalable predictive uncertainty estimation using deep ensembles[C]//Advances in Neural Information Processing Systems (NeurIPS). 2017.
- [13] Pitfalls of conformal predictions for medical image classification[J/OL]. arXiv preprint arXiv:2506.18162, 2025.
- [14] SHAFER G, VOVK V. A tutorial on conformal prediction[J]. Journal of Machine Learning Research, 2008, 9: 371–421.
- [15] When can we reuse a calibration set for multiple conformal predictions?[J/OL]. arXiv preprint arXiv:2506.19689, 2025.
- [16] The challenge of uncertainty quantification of large language models in medicine[J/OL]. arXiv preprint arXiv:2504.05278, 2025.
- [17] ROMANO Y, PATTERSON E, CANDÈS E J. Conformalized quantile regression[C]//Advances in Neural Information Processing Systems (NeurIPS). 2019.
- [18] LEGENDRE A M. Nouvelles méthodes pour la détermination des orbites des comètes[M]. Paris, 1805.
- [19] Adrien-Marie Legendre[EB/OL]. ResearchGate. <https://www.researchgate.net/publication/302274203>.
- [20] The dual of the least-squares method[EB/OL]. IDEAS/RePEc. <https://ideas.repec.org/p/ags/ucdavn/121693.html>.
- [21] Science on the farther shore[EB/OL]. American Scientist. <https://www.americanscientist.org/article/science-on-the-farther-shore>.
- [22] GUNDERSEN G. The Gauss–Markov theorem[EB/OL]. (2022-02-08). <https://gregorygundersen.com/blog/2022/02/08/gauss-markov-theorem/>.
- [23] HOERL A E, KENNARD R W. Ridge regression: biased estimation for nonorthogonal problems[J]. Technometrics, 1970, 12(1): 55–67.
- [24] TIKHONOV A N. Solution of incorrectly formulated problems and the regularization method[J]. Soviet Mathematics Doklady, 1963, 4: 1035–1038.
- [25] HUBER P J. Robust estimation of a location parameter[J]. Annals of Mathematical Statistics, 1964, 35(1): 73–101.
- [26] Forecasting stock market out-of-sample with regularised regression training techniques[EB/OL]. <https://www.sciepub.com/reference/418168>.

- [27] KENDALL A, GAL Y. What uncertainties do we need in Bayesian deep learning for computer vision?[C]//Advances in Neural Information Processing Systems (NeurIPS). 2017.
- [28] Improved uncertainty quantification for neural networks with Bayesian last layer[J/OL]. arXiv preprint arXiv:2302.10975, 2023.
- [29] Variational Bayesian last layers[EB/OL]. OpenReview. <https://openreview.net/forum?id=Sx7BIiPzys>.
- [30] SEITZER M, TAVAKOLI A, ANTIC D, et al. On the pitfalls of heteroscedastic uncertainty estimation with probabilistic neural networks[C]//International Conference on Learning Representations (ICLR). 2022.
- [31] ANGELOPOULOS A N, BATES S. A gentle introduction to conformal prediction and distribution-free uncertainty quantification[J/OL]. arXiv preprint arXiv:2107.07511, 2021.
- [32] Uncertainty quantification in epigenetic clocks via conformalized quantile regression[J/OL]. PMC. <https://pmc.ncbi.nlm.nih.gov/articles/PMC11948180/>.
- [33] Large language model uncertainty measurement and calibration for medical diagnosis and treatment[J/OL]. medRxiv, 2024. <https://www.medrxiv.org/content/10.1101/2024.06.06.24308399v1.full-text>.
- [34] BRIER G W. Verification of forecasts expressed in terms of probability[J]. Monthly Weather Review, 1950, 78(1): 1–3.
- [35] Mind the gap: benchmarking LLM uncertainty and calibration with specialty-aware clinical QA and reasoning-based behavioural features[J/OL]. arXiv preprint arXiv:2506.10769v3, 2025.
- [36] Improving trust in healthcare LLMs via atypical presentations recalibration[C]//Findings of the Association for Computational Linguistics: EMNLP. 2024.
- [37] Stack Overflow. pROC: default DeLong or bootstrap[EB/OL]. <https://stackoverflow.com/questions/47031124/proc-default-delong-or-bootstrap>.
- [38] DELONG E R, DELONG D M, CLARKE-PEARSON D L. Comparing the areas under two or more correlated receiver operating characteristic curves: a nonparametric approach[J]. Biometrics, 1988, 44: 837–845.

- [39] AMOS B, KOLTER J Z. OptNet: differentiable optimization as a layer in neural networks[C]//Proceedings of the International Conference on Machine Learning (ICML). 2017.
- [40] JOHNSON A, et al. MIMIC-IV v2.2[EB/OL]. PhysioNet. <https://physionet.org/content/mimiciv/2.2/>.
- [41] PhysioNet. MIMIC-IV-Ext-22MCTS: a 22 millions-event temporal clinical time-series dataset with relative timestamps[EB/OL]. <https://physionet.org/content/mimic-iv-ext-22mcts/>.
- [42] POLLARD T, et al. The eICU collaborative research database, a freely available multi-center database for critical care research[J/OL]. Scientific Data, 2018. <https://eicu-crd.mit.edu/>.
- [43] IRVIN J, et al. CheXpert: a large chest radiograph dataset with uncertainty labels and expert comparison[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2019.
- [44] Conformal triage for medical imaging AI deployment[J/OL]. medRxiv, 2024.
- [45] Conformal prediction and non-exchangeability in 2025?[EB/OL]. Cross Validated (StackExchange). <https://stats.stackexchange.com/questions/672200/conformal-prediction-non-exchangeability-in-2025>.
- [46] QR versus Cholesky: a probabilistic analysis[J]. International Journal of Numerical Analysis and Modeling, Global Science Press.
- [47] Numerically efficient methods for solving least squares problems[EB/OL]. University of Chicago, 2012. <https://math.uchicago.edu/~may/REU2012/REUPapers/Lee.pdf>.
- [48] Scalable QR factorisation of ill-conditioned tall-and-skinny matrices on distributed GPU systems[J]. MDPI Mathematics, 2025, 13(22): 3608.
- [49] Randomized Cholesky QR factorizations[J/OL]. arXiv preprint arXiv:2210.09953, 2022.
- [50] Performance comparison of three prospective models using DeLong and bootstrap tests[EB/OL]. ResearchGate. <https://www.researchgate.net/figure/Performance-comparison-of-three-prospective-models-using-DeLong-and-bootstrap-tests>
- [51] PhysioNet credentialed health data use agreement 1.5.0[EB/OL]. PhysioNet. <https://physionet.org/content/mimic-iv-ext-22mcts/view-dua/1.0.0/>.